Tipología y ciclo de vida de los datos. Práctica 2

Baltasar Boix / Yago Ezcurra

13/5/2021

Contents

1 Titanic - Machine Learning from Disaster. Kaggle competition.

```
library(dplyr)
library(ggplot2)
library(tidyverse)
require(lares)
library(GGally)
library(knitr)
library(kableExtra)
library(gridExtra)
library(DescTools)
library(caret)
library(VIM)
```

2 Descripción del dataset. ¿Por qué es importante y qué pregunta/problema pretende responder?

2.1 Lectura y analisis previo del dataset.

```
# Lectura de datos de entrenamiento y prueba
df <- read_csv('../data/train.csv')
df_t <- read_csv('../data/test.csv')
df_t$Survived <- NA

# Conjunto de datos completo
df <- bind_rows(df, df_t)

# Factorizamos las variables
df$Survived <- factor(df$Survived)
df$Pclass <- factor(df$Pclass)
df$Sex <- factor(df$Sex)
df$SibSp <- factor(df$SibSp)
df$Parch <- factor(df$Parch)
df$Embarked <- factor(df$Embarked)
summary(df)
```

```
##   PassengerId   Survived   Pclass      Name              Sex
##  Min.   :   1   0   :549   1:323   Length:1309        female:466
##  1st Qu.: 328   1   :342   2:277   Class :character   male  :843
##  Median : 655   NA's:418   3:709   Mode  :character
##  Mean   : 655
##  3rd Qu.: 982
##  Max.   :1309
##
##       Age         SibSp       Parch         Ticket              Fare
##  Min.   : 0.17   0:891   0      :1002   Length:1309        Min.   :  0.000
##  1st Qu.:21.00   1:319   1      : 170   Class :character   1st Qu.:  7.896
##  Median :28.00   2: 42   2      : 113   Mode  :character   Median : 14.454
##  Mean   :29.88   3: 20   3      :   8                      Mean   : 33.295
##  3rd Qu.:39.00   4: 22   4      :   6                      3rd Qu.: 31.275
##  Max.   :80.00   5:  6   5      :   6                      Max.   :512.329
##  NA's   :263     8:  9   (Other):   4                      NA's   :1
##     Cabin           Embarked
##  Length:1309        C   :270
##  Class :character   Q   :123
##  Mode  :character   S   :914
##                     NA's:  2
##
##
##
```

```
df_str(df)
```

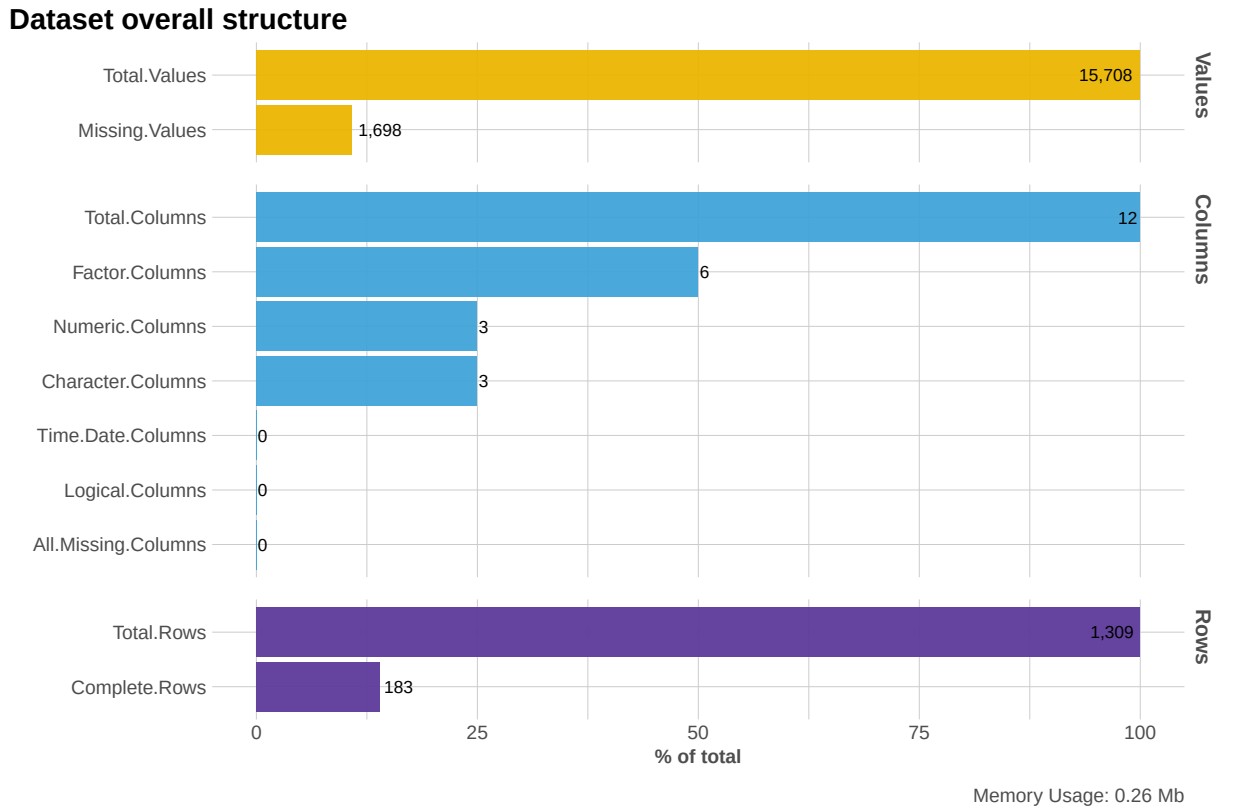

El conjunto de datos objeto de análisis se ha obtenido a partir Titanic que contiene datos sobre la supervivencia de pasajeros a bordo del Titanic. Los datos se han dividido en dos grupos:

1. El conjunto de datos de entrenamiento (train.csv). Está constituido por 891 pasajeros (filas o registros) que presentan 12 características (columnas).
2. El conjunto de datos de pruebas (test.csv). Está constituido por 418 pasajeros (filas o registros) que presentan 12 características (columnas).

Los campos de este conjunto son los siguientes:

Para este trabajo se combinan los **datos de entrenamiento** y **datos de pruebas** en un único conjunto de datos. Por tanto, este conjunto de datos contiene 1309 registros y 12 características

Data Dictionary

Variable	Definition	Key
survival	Survival	0 = No, 1 = Yes
pclass	Ticket class	1 = 1st, 2 = 2nd, 3 = 3rd
sex	Sex	
Age	Age in years	
sibsp	# of siblings / spouses aboard the Titanic	
parch	# of parents / children aboard the Titanic	
ticket	Ticket number	
fare	Passenger fare	
cabin	Cabin number	
embarked	Port of Embarkation	C = Cherbourg, Q = Queenstown, S = Southampton

Variable Notes

pclass: A proxy for socio-economic status (SES)
1st = Upper
2nd = Middle
3rd = Lower

age: Age is fractional if less than 1. If the age is estimated, is it in the form of xx.5

sibsp: The dataset defines family relations in this way...
Sibling = brother, sister, stepbrother, stepsister
Spouse = husband, wife (mistresses and fiancés were ignored)

parch: The dataset defines family relations in this way...
Parent = mother, father
Child = daughter, son, stepdaughter, stepson
Some children travelled only with a nanny, therefore parch=0 for them.

Figure 1: Descripción del dataset obtenido en Kaggle

2.2 Importancia y objetivos de los análisis.

A partir de este conjunto de datos se plantea la problemática de determinar qué variables influyen más sobre la supervivencia de los pasajeros a bordo del Titanic. Además, se podrá proceder a crear modelos de aprendizaje supervisado que permitan predecir la supervivencia de una persona en función de sus características y contrastes de hipótesis que ayuden a identificar propiedades interesantes en las muestras que puedan ser inferidas con respecto a la población.

3 Integración y selección de los datos de interés a analizar.

A partir de los datos, se decide extraer información de las siguientes características:

- Creamos la variable dicotómica `Child` para diferenciar los niños de los adultos (>12años).
- De la característica `Name` se extrae el título y el apellido de la familia.
- De la característica `Ticket`, se crea la variable `n_ticket` con el número de personas que viajan con el mismo ticket. .
- De las características `Cabin` se extraen el deck en el que estaba.
- De las características `Fare` se extraen las personas que pertenecían a la tripulación (Fare==0).

3.0.1 Característica Child (Name)

La variable nombre del pasajero podemos dividirla en el titulo y en el apellido. Además, para facilitar el análisis simplificamos `title_name` en cuatro niveles. Por ejemplo, el título del pasajero está contenido dentro de la variable de nombre del pasajero (Por ejemplo, 'Mr', 'Miss') y podemos usar el apellido para representar a las familias.

```
df <- df %>%
  mutate(Child=factor(Age<=12))
```

3.0.2 Característica n_ticket (Ticket)

```
df <- left_join(df, df %>%
group_by(Ticket) %>%
summarize(n_ticket=n())) %>%
mutate(n_ticket=factor(n_ticket))
```

3.0.3 Característica Nombre (Name)

La variable nombre del pasajero podemos dividirla en el titulo y en el apellido. Además, para facilitar el análisis simplificamos `title_name` en cuatro niveles. Por ejemplo, el título del pasajero está contenido dentro de la variable de nombre del pasajero (Por ejemplo, 'Mr', 'Miss') y podemos usar el apellido para representar a las familias.

```
df <- df %>%
  separate(Name, c('first_name', 'rest_name'), sep=', ', remove=F) %>%
  separate(rest_name, c('title_name', 'rest_name'), sep='\\.') %>%
  select(-rest_name)

df$title_name[df$title_name %in% c('Capt', 'Col', 'Don', 'Dr', 'Jonkheer',
                                   'Major', 'Rev', 'Sir')] <- 'Mr'

df$title_name[df$title_name %in% c('Lady', 'Mme','the Countess', 'Dona')] <- 'Mrs'

df$title_name[df$title_name %in% c('Mlle', 'Ms')] <- 'Miss'
df$title_name <- factor(df$title_name)
```

3.0.4 Característica n_name (nº de pasajeros con el mismo apellido)

```
df <- left_join(df, df %>%
                  group_by(Pclass, first_name) %>%
```

```
                  summarize(n_name=n())) %>%
  mutate(n_name=factor(n_name))
```

3.0.5 Característica cabina (Cabin)

```
df <- df %>%
  mutate(Deck=if_else(is.na(Cabin), 'N', str_sub(Cabin, 1, 1) )) %>%
  mutate(Deck=factor(Deck))
```

3.0.6 Característica Tripulación (Crew)

De la variable `Fare` se genera una nueva variable `Crew`. Esta variable diferencia a los pasajeros de los tripulantes, ya que los tripulantes no han pagado por ir en el barco.

```
df <- df %>%
  mutate(Crew=factor(if_else(Fare==0, TRUE, FALSE)))
```

Representamos graficamente la variable dependiente `Survived` frente a cada valor posible de las variables categóricas. Podemos observar directamente que, por ejemplo, el `title_name` 'Mrs' tiene una supervivencia muy superior al la de 'Mr'.

```
df %>%
  select(where(is.factor)) %>%
  na.omit() %>%
  pivot_longer(-Survived) %>%
  group_by(name, value, Survived) %>%
  summarize(n=n()) %>%
  mutate(prop=prop.table(n)) %>%
  pivot_longer(c(n,prop), names_to='tipo', values_to='val') %>%
  ggplot(aes(x=interaction(name,value, lex.order = T), y=val, fill=Survived)) +
    geom_bar(stat='identity', position='stack') +
    facet_grid(tipo ~ ., scale='free_y') +
    theme(axis.text.x = element_text(angle = 90, vjust = 1, hjust=1))
```

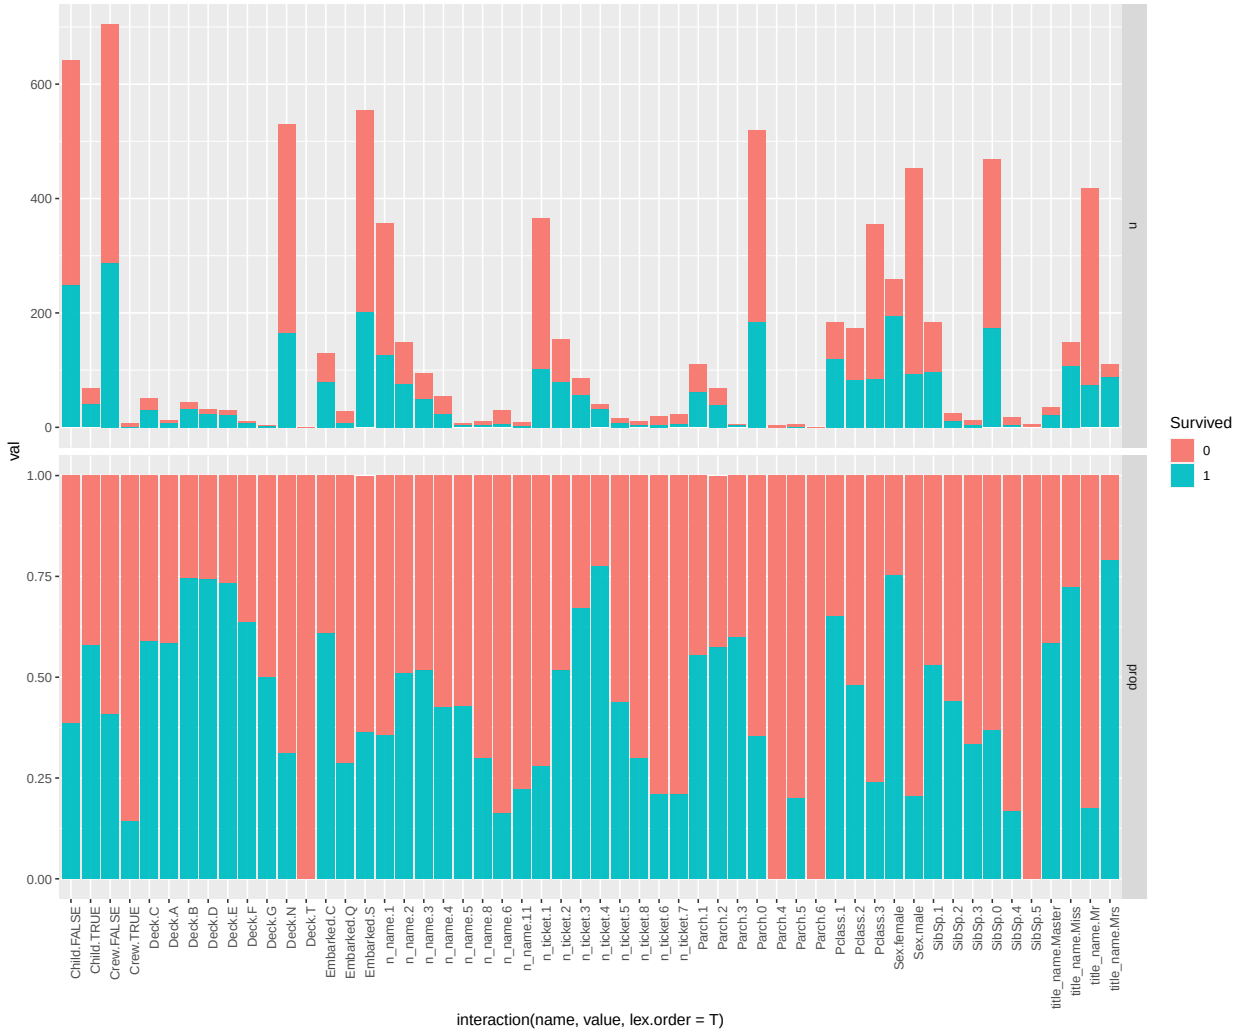

El gráfico `pairs` nos muestra cómo se distribuyen las variables numéricas separando los subsets con `Survived` 1 y 0 (NA's para los pasajeros de 'test.csv'). Ya podemos observar que los pasajeros con `Fare` más alto tuvieron un porcentaje de superviviencia mayor).

```
df %>%
  select(Survived, where(is.numeric), -PassengerId) %>%
  ggpairs(aes(color=Survived))
```

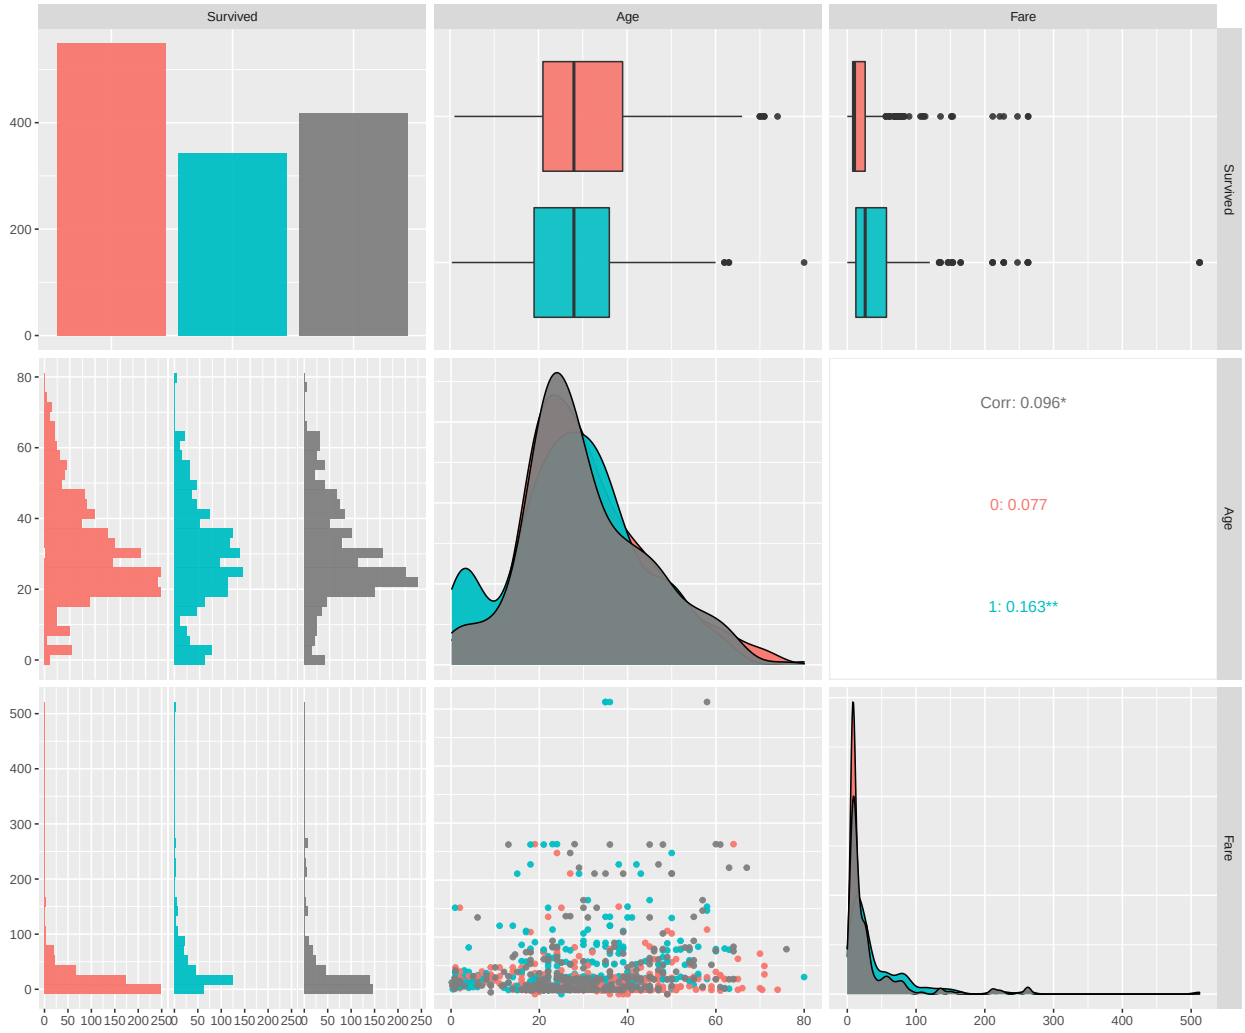

3.1 Selección de los datos de interes

La gran mayoría de los atributos presentes se corresponden con las características que representan a todos los tripulantes del Titanic, por lo que será conveniente tenerlos en consideración durante la realización de los análisis. Sin embargo, podemos prescindir de los campos (PassengerId, Name y Cabin) dado que no son atributos a los que se les ha extraído la información relevante en el paso anterior, por tanto, nos añadirían redundancia a la hora de resolver nuestro problema.

```
# Eliminamos las siguinetes columnas
# df$PassengerId <-NULL
# df$Name <-NULL
# df$Cabin <- NULL
```

4 Limpieza de los datos.

4.1 Ceros o elementos vacíos

En primer lugar, analizamos la cantidad de valores nulos que existen por cada atributo.

```
# Números de valores desconocidos por campo
sapply(df, function(x) sum(is.na(x)))
```

```
## PassengerId    Survived      Pclass        Name  first_name  title_name
```

```
##           0         418           0           0           0           0
##         Sex         Age       SibSp       Parch      Ticket        Fare
##           0         263           0           0           0           1
##       Cabin    Embarked       Child    n_ticket      n_name        Deck
##        1014           2         263           0           0           0
##        Crew
##           1
```

Dado los resultados anteriores las características vemos que la variable `Survived` tiene 418 valores **NA**. Esto se debe a que esta característica no está en el conjunto de datos de prueba.

Por tanto, las variables de interés que tienen valores perdidos ordenadas de mayor a menor son: `Age`, `Embarked` y `Fare`.

4.1.1 Característica Child

Llegados a este punto debemos decidir cómo manejar estos registros que contienen valores desconocidos para algún campo. Una opción podría ser eliminar esos registros que incluyen este tipo de valores, pero ello supondría desaprovechar información. Por lo que aplicaremos a continuación distintas técnicas para imputar esos valores.

Sustituimos los NA's de la variable Child con los siguientes criterios aplicados consecutivamente:

- `Asumimos que los viajeros con ticket unipersonal con SibSp==0 (sin hermanos o esposa a bordo) y Par`
- `Asumimos que las personas con title_name=='Mrs' (mujeres casadas) no son niños.`
- `Asumimos que las personas con title_name=='Master' son niños.`
- `Asumimos que las personas con SibSp>0 y Parch>0 son niños.`
- `Los no asignados anteriormente no son niños.`

```
df <- df %>%
  mutate(Child = if_else(SibSp == 0 & Parch == 0 & is.na(Child) & n_ticket == 1,
                         FALSE, as.logical(Child) )) %>%
  mutate(Child = if_else(title_name == 'Master' & is.na(Child),
                         TRUE, as.logical(Child))) %>%
  mutate(Child = if_else(title_name == 'Mrs' & is.na(Child),
                         FALSE, as.logical(Child))) %>%
  mutate(Child = if_else(SibSp != '0' & Parch != '0' & is.na(Child),
                         TRUE, as.logical(Child))) %>%
  mutate(Child = if_else(is.na(Child), FALSE, as.logical(Child))) %>%
  mutate(Child=factor(Child))
prop.table(table(df$Survived, df$Child, dnn = c('Survived', 'Child')), margin = 2)
```

```
##          Child
## Survived     FALSE      TRUE
##        0 0.6290323 0.4941176
##        1 0.3709677 0.5058824
```

4.1.2 Característica Embarque

Solo hay dos pasajeras que no tienen el puerto de embarque registrado. Comparten Ticket y camarote. Les asignamos el puerto en el que emnbarcaron más pasajeros.

```
df[is.na(df$Embarked),]
```

```
## # A tibble: 2 x 19
##   PassengerId Survived Pclass Name       first_name title_name Sex     Age SibSp
##         <dbl> <fct>    <fct>  <chr>      <chr>      <fct>      <fct> <dbl> <fct>
## 1          62 1        1      Icard, Mi~ Icard      Miss       fema~    38 0
## 2         830 1        1      Stone, Mr~ Stone      Mrs        fema~    62 0
## # ... with 10 more variables: Parch <fct>, Ticket <chr>, Fare <dbl>,
## #   Cabin <chr>, Embarked <fct>, Child <fct>, n_ticket <fct>, n_name <fct>,
## #   Deck <fct>, Crew <fct>
```

```
table(df$Embarked)
```

```
##
##   C   Q   S
## 270 123 914
```

```
df$Embarked[is.na(df$Embarked)] <- 'S'
```

4.1.3 Característica tarifa

Para reemplazar el valor que nos falta de tarifa (`Fare`) se empleará un método de imputación de valores basado en la similitud o diferencia entre los registros: la imputación basada en k vecinos más próximos (en inglés, kNN-imputation). La elección de esta alternativa se realiza bajo la hipótesis de que nuestros registros guardan cierta relación. No obstante, es mejor trabajar con datos "aproximados" que, con los propios elementos vacíos, ya que obtendremos análisis con menor margen de error.

```
# Imputación de valores mediante la función kNN() del paquete VIM
df$Fare<- kNN(df)$Fare
df <- df %>%
  mutate(Crew=factor(if_else(Fare==0, TRUE, FALSE)))
```

4.1.4 Característica Edad

Por último, para imputar los valores **NA** de la variable edad (`Age`), se empleara también una imputación de kNN.

```
# Imputación de valores mediante la función kNN() del paquete VIM
df$Age <- kNN(df)$Age

sapply(df, function(x) sum(is.na(x)))
```

```
## PassengerId    Survived      Pclass        Name  first_name  title_name
##           0         418           0           0           0           0
##         Sex         Age       SibSp       Parch      Ticket        Fare
##           0           0           0           0           0           0
##       Cabin    Embarked       Child    n_ticket      n_name        Deck
##        1014           0           0           0           0           0
##        Crew
##           0
```

4.2 Identificación y tratamiento de valores extremos.

Los valores extremos o outliers son aquellos datos que se encuentran muy alejados de la distribución normal de una variable o población. Para identificarlos, podemos hacer uso de dos vías: (1) representar un diagrama de caja por cada variable y ver qué valores distan mucho del rango intercuartílico (la caja) o (2) utilizar la función boxplots.stats() de R.

A continuación se muestra los valores atípicos para las variables cuantitiativass (Age y Fare) mediante la representación de un diagrama de caja.

```
# Identificación de valores extremos
par(mfrow=c(1,2))
boxplot(df$Age, main= "Age")
boxplot(df$Fare, main= "Fare")
```

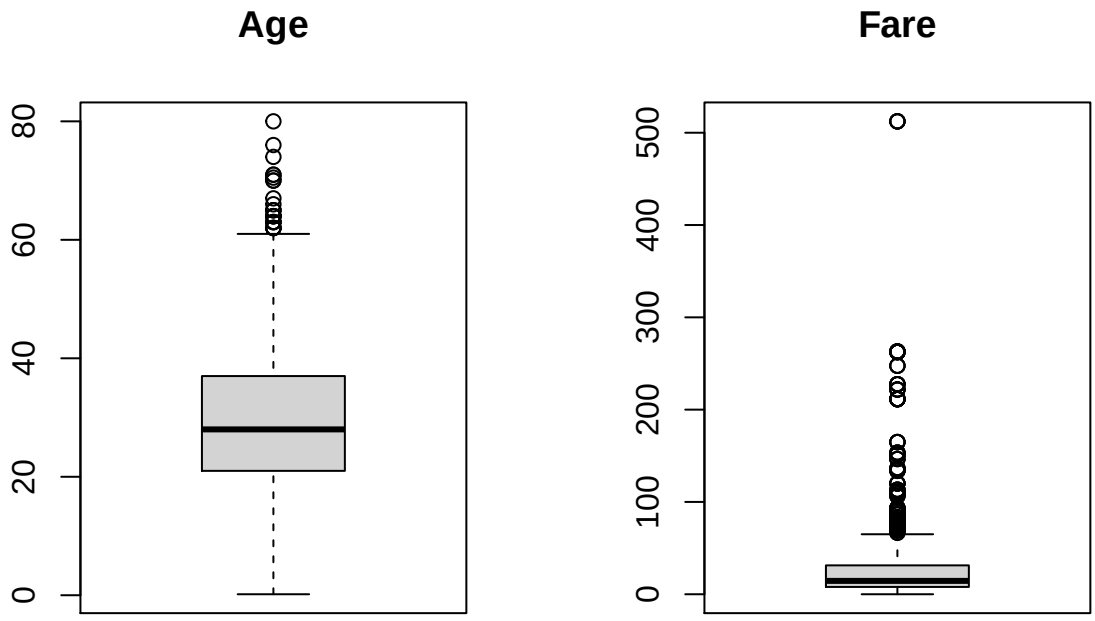

Para los resultados de la característica edad (Age) los valores extremos son valores reales y están en un rango normal. No hay edades mayores a 80 ni menores a 0. Por tanto, son valores que pueden darse.

Para los resultados de la característica tarifa (Fare) sí que vemos una mayor discrepancia en la distribución con precios 5 veces más grandes que la media. Estos valores están relacionados con la clase y el número de pasajeros. Por tanto, son valores que pueden darse.

4.3 Exportación de los datos preprocesados

5 Análisis de los datos.

5.1 Selección de los grupos de datos que se quieren analizar/comparar (planificación de los análisis a aplicar).

A continuación, se seleccionan los grupos dentro de nuestro conjunto de datos que pueden resultar interesantes para analizar y/o comparar. En este caso nos interesa analizar las diferencias de supervivencia entre hombres y mujeres y distintas clases.

```
# Agrupación por sexo
titanic.male <- df[df$Sex == "male",]
titanic.female <- df[df$Sex == "female",]
```

```
# Agrupación por clase
titanic.first <- df[df$Pclass == "1",]
titanic.second <- df[df$Pclass == "2",]
titanic.third <- df[df$Pclass == "3",]
```

5.2 Comprobación de la normalidad y homogeneidad de la varianza.

de una población distribuida normalmente, utilizaremos la prueba de normalidad de Shapiro-Wilk, al tratarse de uno de los métodos más potentes para contrastar la normalidad. Asumiendo como hipótesis nula que la población está distribuida normalmente, si el p-valor es menor al nivel de significancia, generalmente $\alpha = 0.05$, entonces la hipótesis nula es rechazada y se concluye que los datos no cuentan con una distribución normal.

```
# Shapiro-Wilk test para Age
shapiro.test(df$Age)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df$Age
## W = 0.97635, p-value = 7.966e-14
```

```
# Shapiro-Wilk test para Fare
shapiro.test(df$Fare)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  df$Fare
## W = 0.52765, p-value < 2.2e-16
```

Dado los resultados anteriores,se observa que para la variable Age y la variable Fare consideradas sus correspondientes p-valores son inferiores al nivel de significación ($\alpha = 0.05$). Por tanto, rechazamos la hipotesis nula y conluimos con un 95% de confianza que los datos no se distribuyen normalmente.

Seguidamente, pasamos a estudiar la homogeneidad de varianzas, mediante la aplicación de un test de Fligner-Killeen. Se trata de uun test no parametrico que compara las varianzas basandose en la mediana. Para realizar el test de Fligner-Killen se utiliza la funcion *fligner.test()*

A continuación, se muestra la aplicación del test Fligner-Killeen para la característica cuantitativas Edad (Age) en función de la Supervivencia (Survived):

```
# Test Fligner-Killeen para Age
fligner.test(Age ~ Survived, data = df)
```

```
##
##  Fligner-Killeen test of homogeneity of variances
##
## data:  Age by Survived
## Fligner-Killeen:med chi-squared = 3.3483, df = 1, p-value = 0.06728
```

Puesto que obtenemos un p-valor superior al nivel de significación ($\alpha = 0.05$), aceptamos la hipótesis nula, es decir, de que las varianzas de ambas muestras son homogéneas.

A continuación, se muestra la aplicación del test Fligner-Killeen para característica precio (Fare) en función de la Supervivencia (Survived):

```
# Test fligner para SibSp
fligner.test(Fare ~ Survived, data = df)
```

```
##
##  Fligner-Killeen test of homogeneity of variances
##
## data:  Fare by Survived
## Fligner-Killeen:med chi-squared = 96.253, df = 1, p-value < 2.2e-16
```

Puesto que obtenemos un p-valor inferior al nivel de significación, rechazamos la hipótesis nula (H_0), es decir, podemos concluir que las varianzas son significativamente diferentes.

5.3 Aplicación de pruebas estadísticas para comparar los grupos de datos. En función de los datos y el objetivo del estudio, aplicar pruebas de contraste de hipótesis, correlaciones, regresiones, etc. Aplicar al menos tres métodos de análisis diferentes.

Para determinar la asociación de la variable `Survived` con el resto de variables categóricas utilizamos el test χ^2 y el coeficiente CramerV. Según el test χ^2 todas las variables son significativas con un 95% de confianza. La bibliografía indica que un valor de CramerV > 0.1 es significativo. Las variables `Child` y `Crew` no lo cumplen por poco.

Para determinar la asociación de la variable `Survived` con las variables numéricas utilizaremos el t.test (H_0: la media del subset con `Survived==1` es igual a la media con `Survived==0`). En el caso de las variables `Age` y `Fare` podemos descartar que tengan la misma media con un 95% de confianza. Previamente determinamos si la varianza de los subset pueden considerarse iguales. Son iguales en la variable `Age` y diferentes en la `Fare` (Utilizamos estos resultados en el cálculo del t.test).

Ajustamos un modelo GLM y minimizamos el Aic con la función `step` (búsqueda de las variables más significativas). El modelo con menor Aic:

- `` `Survived ~ Pclass + title_name + Age + SibSp + Parch + Fare + n_ticket + n_name` ``

El modelo consigue una precisión de un 83.8% sobre los datos de entrenamiento.

Los dos primeros métodos identifican la asociación de cada variable individualmente. GLM tiene en cuenta la colinearidad de las variables.

```
df %>%
  select(Survived, where(is.factor)) %>%
  filter(!is.na(Survived)) %>%
  pivot_longer(-Survived) %>%
  group_by(name) %>%
  summarize(cramerv=CramerV(x=Survived, y=factor(value)),
            chisq.pvalue=chisq.test(Survived, factor(value))$p.value) %>%
  mutate(`signif 95%`=chisq.pvalue < 0.05) %>%
  arrange(chisq.pvalue) %>%
  kable(format='latex', digits=4, caption='CramerV y chisq.test') %>%
  kable_styling(full_width = F, latex_options = "HOLD_position")
```

Table 1: CramerV y chisq.test

name	cramerv	chisq.pvalue	signif 95%
title_name	0.5708	0.0000	TRUE
Sex	0.5434	0.0000	TRUE
Pclass	0.3398	0.0000	TRUE
n_ticket	0.3388	0.0000	TRUE
Deck	0.3336	0.0000	TRUE
SibSp	0.2045	0.0000	TRUE
Embarked	0.1707	0.0000	TRUE
n_name	0.1979	0.0000	TRUE
Parch	0.1770	0.0001	TRUE
Child	0.0815	0.0206	TRUE
Crew	0.0853	0.0226	TRUE

```
df %>%
  select(Survived, where(is.numeric), -PassengerId) %>%
  filter(!is.na(Survived)) %>%
  pivot_longer(-Survived) %>%
  group_by(name, Survived) %>%
  summarize(value_list = list(value)) %>%
```

```
  pivot_wider(names_from=Survived, values_from=value_list) %>%
  mutate(vartest.pval=var.test(unlist(`0`), unlist(`1`))$p.val) %>%
  mutate(ttest.pval=t.test(unlist(`0`), unlist(`1`),
                           var.equal=vartest.pval>0.05)$p.val) %>%
  mutate(`signif 95%`=ttest.pval < 0.05) %>%
  select(-`0`, -`1`)  %>%
  kable(format='latex', digits=4, caption='t.test') %>%
  kable_styling(full_width = F, latex_options = "HOLD_position")
```

Table 2: t.test

name	vartest.pval	ttest.pval	signif 95%
Age	0.2075	0.038	TRUE
Fare	0.0000	0.000	TRUE

```
# GLM
df0 <- df %>%
  select(-PassengerId, -Name, -first_name, -Ticket, -Cabin) %>%
  na.omit()
fit <- glm(data=df0, Survived ~ ., family=binomial(link = "logit"))
step_fit <- step(fit, direction='both')
```

```
## Start:  AIC=720.16
## Survived ~ Pclass + title_name + Sex + Age + SibSp + Parch +
##     Fare + Embarked + Child + n_ticket + n_name + Deck + Crew
##
##              Df Deviance    AIC
## - Deck        8   637.71 715.71
## - Child       1   626.18 718.18
## - Embarked    2   628.84 718.84
## - Crew        1   627.48 719.48
## - Sex         1   627.61 719.61
## <none>            626.16 720.16
## - Fare        1   629.35 721.35
## - n_name      7   647.92 727.92
## - Parch       6   646.81 728.81
## - Age         1   640.46 732.46
## - Pclass      2   650.37 740.37
## - n_ticket    7   667.39 747.39
## - SibSp       5   668.87 752.87
## - title_name  3   665.66 753.66
##
## Step:  AIC=715.71
## Survived ~ Pclass + title_name + Sex + Age + SibSp + Parch +
##     Fare + Embarked + Child + n_ticket + n_name + Crew
##
##              Df Deviance    AIC
## - Child       1   637.71 713.71
## - Embarked    2   640.15 714.15
## - Crew        1   639.50 715.50
## <none>            637.71 715.71
## - Sex         1   639.83 715.83
## - Fare        1   640.44 716.44
## + Deck        8   626.16 720.16
## - n_name      7   659.14 723.14
## - Parch       6   658.06 724.06
## - Age         1   651.45 727.45
## - n_ticket    7   679.89 743.89
## - SibSp       5   680.39 748.39
## - title_name  3   679.56 751.56
## - Pclass      2   687.20 761.20
##
## Step:  AIC=713.71
## Survived ~ Pclass + title_name + Sex + Age + SibSp + Parch +
##     Fare + Embarked + n_ticket + n_name + Crew
```

```
##
##              Df Deviance    AIC
## - Embarked    2   640.18 712.18
## - Crew        1   639.51 713.51
## <none>            637.71 713.71
## - Sex         1   639.83 713.83
## - Fare        1   640.68 714.68
## + Child       1   637.71 715.71
## + Deck        8   626.18 718.18
## - n_name      7   659.15 721.15
## - Parch       6   658.06 722.06
## - Age         1   652.48 726.48
## - n_ticket    7   679.90 741.90
## - SibSp       5   680.39 746.39
## - Pclass      2   688.06 760.06
## - title_name  3   690.76 760.76
##
## Step:  AIC=712.18
## Survived ~ Pclass + title_name + Sex + Age + SibSp + Parch +
##     Fare + n_ticket + n_name + Crew
##
##              Df Deviance    AIC
## - Crew        1   642.17 712.17
## <none>            640.18 712.18
## - Sex         1   642.20 712.20
## + Embarked    2   637.71 713.71
## - Fare        1   643.73 713.73
## + Child       1   640.15 714.15
## + Deck        8   628.84 716.84
## - n_name      7   660.75 718.75
## - Parch       6   660.19 720.19
## - Age         1   655.67 725.67
## - n_ticket    7   682.01 740.01
## - SibSp       5   681.94 743.94
## - Pclass      2   689.72 757.72
## - title_name  3   692.42 758.42
##
## Step:  AIC=712.17
## Survived ~ Pclass + title_name + Sex + Age + SibSp + Parch +
##     Fare + n_ticket + n_name
##
##              Df Deviance    AIC
## <none>            642.17 712.17
## + Crew        1   640.18 712.18
## - Sex         1   644.28 712.28
## + Embarked    2   639.51 713.51
## + Child       1   642.17 714.17
## - Fare        1   647.41 715.41
## + Deck        8   630.45 716.45
## - n_name      7   662.74 718.74
## - Parch       6   662.44 720.44
## - Age         1   657.56 725.56
## - n_ticket    7   684.40 740.40
## - SibSp       5   684.84 744.84
## - Pclass      2   689.76 755.76
## - title_name  3   695.58 759.58
```

```
summary(step_fit)
```

```
##
## Call:
## glm(formula = Survived ~ Pclass + title_name + Sex + Age + SibSp +
##     Parch + Fare + n_ticket + n_name, family = binomial(link = "logit"),
##     data = df0)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -2.2614  -0.4672  -0.2992   0.4569   2.6211
##
```

```
## Coefficients: (1 not defined because of singularities)
##                 Estimate Std. Error z value Pr(>|z|)
## (Intercept)      23.99703 3956.18050   0.006 0.995160
## Pclass2          -1.44944    0.36774  -3.941 8.10e-05 ***
## Pclass3          -2.57274    0.38580  -6.669 2.58e-11 ***
## title_nameMiss  -19.73389 3956.18049  -0.005 0.996020
## title_nameMr     -4.66066    0.83524  -5.580 2.40e-08 ***
## title_nameMrs   -18.88969 3956.18050  -0.005 0.996190
## Sexmale         -18.21254 3956.18041  -0.005 0.996327
## Age              -0.04073    0.01075  -3.789 0.000151 ***
## SibSp1            0.29142    0.35415   0.823 0.410579
## SibSp2            1.22251    0.71822   1.702 0.088730 .
## SibSp3            0.32039    1.13234   0.283 0.777220
## SibSp4          -18.17148  839.89941  -0.022 0.982739
## SibSp5          -44.08829 1695.15924  -0.026 0.979251
## SibSp8          -36.51632 1440.36402  -0.025 0.979774
## Parch1           -0.05667    0.40483  -0.140 0.888669
## Parch2            0.42621    0.62015   0.687 0.491912
## Parch3            1.59415    1.63027   0.978 0.328153
## Parch4          -13.02690 1625.15898  -0.008 0.993604
## Parch5          -15.88408  839.90167  -0.019 0.984911
## Parch6          -42.62142 4044.35354  -0.011 0.991592
## Fare              0.00870    0.00443   1.964 0.049529 *
## n_ticket2        -0.63038    0.36189  -1.742 0.081524 .
## n_ticket3        -0.22091    0.50212  -0.440 0.659969
## n_ticket4        -0.19257    0.77828  -0.247 0.804575
## n_ticket5        -2.77100    0.90102  -3.075 0.002102 **
## n_ticket6        -4.85743    1.36294  -3.564 0.000365 ***
## n_ticket7        -4.32455    1.88808  -2.290 0.021995 *
## n_ticket8         3.21451    0.90126   3.567 0.000362 ***
## n_ticket11             NA         NA      NA       NA
## n_name2          -0.40455    0.37439  -1.081 0.279894
## n_name3          -0.71893    0.46918  -1.532 0.125439
## n_name4          -1.26050    0.58802  -2.144 0.032062 *
## n_name5          -1.89627    1.44918  -1.309 0.190697
## n_name6          -0.94818    1.06019  -0.894 0.371134
## n_name8          20.35827  839.89981   0.024 0.980662
## n_name11         16.97264  839.89768   0.020 0.983877
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 1186.66  on 890  degrees of freedom
## Residual deviance:  642.17  on 856  degrees of freedom
## AIC: 712.17
##
## Number of Fisher Scoring iterations: 16
confusionMatrix(factor(as.numeric(predict(step_fit, type='response')>0.5)), df0$Survived)

## Confusion Matrix and Statistics
##
##           Reference
## Prediction   0   1
##          0 481  77
##          1  68 265
##
##                Accuracy : 0.8373
##                  95% CI : (0.8114, 0.8609)
##     No Information Rate : 0.6162
##     P-Value [Acc > NIR] : <2e-16
##
##                   Kappa : 0.6542
##
##  Mcnemar's Test P-Value : 0.5065
##
##             Sensitivity : 0.8761
##             Specificity : 0.7749
```

```
##          Pos Pred Value : 0.8620
##          Neg Pred Value : 0.7958
##              Prevalence : 0.6162
##          Detection Rate : 0.5398
##    Detection Prevalence : 0.6263
##       Balanced Accuracy : 0.8255
##
##        'Positive' Class : 0
##
```

6 Representación de los resultados a partir de tablas y gráficas.

7 Resolución del problema. A partir de los resultados obtenidos, ¿cuáles son las conclusiones? ¿Los resultados permiten responder al problema?

Claramente la supervivencia en el naufragio del Titanic se priorizó a las mujeres, los niños y a los pasajeros de primera clase.

El modelo SVM ajustado para participar en el concurso de Kaggle consigue una precisión aceptable (determinada por cross validation de 10 grupos).

La precisión calculada por cross-validation es de un 84.7%. Es decir se divide el dataset de training en 10 subsets sin elementos comunes. Se utilizan 9 para ajustar el modelo y el décimo para calcular la precisión. Se repite el proceso dejando fuera del ajuste un subset diferente cada vez. En el gráfico podemos ver la precisión para cada uno de los valores del Coste ensayados. El punto representa la media de las precisiones calculadas y la barra de error el rango del 95% de confianza.

Si aplicamos el modelo ajustado al conjunto de los datos de training obtenemos una precisión del 98.9%.

Por último, generamos el fichero 'My_submission.csv' que mandaremos a Kaggle. Debemos esperar un rango de precisión con un 95% de confianza: (0.774, 0.921). El que nos reporta Kaggle: 0.78229.

```
df0 <- df %>%
  select(-PassengerId, -Name, -Cabin) %>%
  mutate(first_name=factor(first_name)) %>%
  mutate(Ticket=factor(Ticket)) %>%
  na.omit()
set.seed(200560)
train_control <- trainControl(method="cv", number=10)
# Fit the model
svm1 <- train(Survived ~ ., data = df0, method = 'svmLinear', trControl = train_control,
              tuneGrid = expand.grid(C = seq(0, 2, length = 10)))
svm1
```

```
## Support Vector Machines with Linear Kernel
##
## 891 samples
##  15 predictor
##   2 classes: '0', '1'
##
## No pre-processing
## Resampling: Cross-Validated (10 fold)
## Summary of sample sizes: 802, 801, 802, 802, 803, 802, ...
## Resampling results across tuning parameters:
##
##   C          Accuracy   Kappa
##   0.0000000        NaN        NaN
##   0.2222222  0.8317058  0.6393967
##   0.4444444  0.8463509  0.6722825
##   0.6666667  0.8474370  0.6774003
##   0.8888889  0.8463512  0.6749678
##   1.1111111  0.8452276  0.6724751
```

```
##   1.3333333  0.8463387  0.6750447
##   1.5555556  0.8452151  0.6728147
##   1.7777778  0.8440787  0.6701865
##   2.0000000  0.8440787  0.6701865
##
## Accuracy was used to select the optimal model using the largest value.
## The final value used for the model was C = 0.6666667.
```

```
ggplot(svm1$results, aes(x=C, y=Accuracy)) +
  geom_point() +
  geom_line() +
  geom_errorbar(aes(ymin=Accuracy - 1.96*AccuracySD, ymax=Accuracy + 1.96*AccuracySD), color='blue') +
  ggtitle ('Precisión vs factor Coste', subtitle='Rango 95% confianza')
```

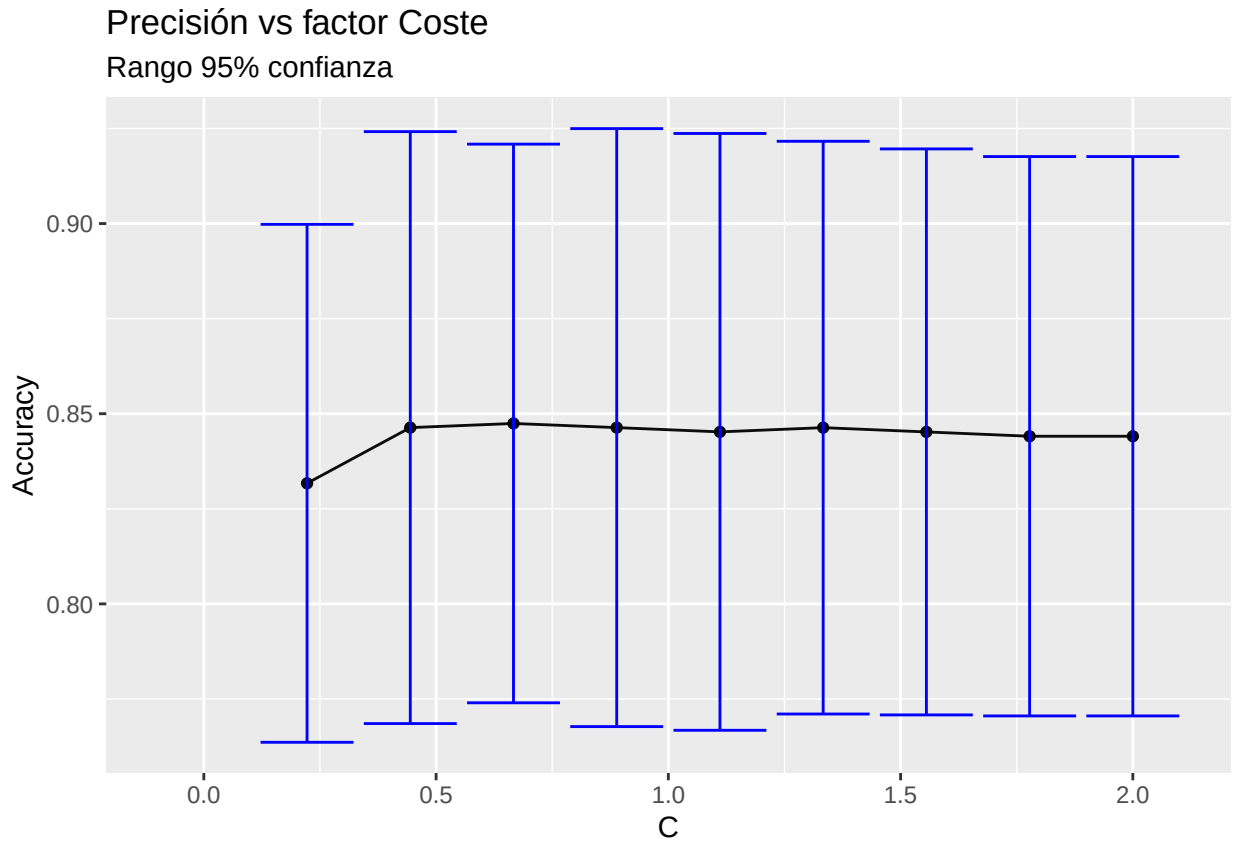


```
cat('Rango de precisión esperada:', round(svm1$results[4,2]-1.96*svm1$results[4,4]*c(1, -1),3))
```

```
## Rango de precisión esperada: 0.774 0.921
```

```
confusionMatrix(predict(svm1), df0$Survived)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction   0   1
##          0 546   7
##          1   3 335
##
##                Accuracy : 0.9888
##                  95% CI : (0.9795, 0.9946)
##     No Information Rate : 0.6162
##     P-Value [Acc > NIR] : <2e-16
##
##                   Kappa : 0.9762
##
```

```
##  Mcnemar's Test P-Value : 0.3428
##
##             Sensitivity : 0.9945
##             Specificity : 0.9795
##          Pos Pred Value : 0.9873
##          Neg Pred Value : 0.9911
##              Prevalence : 0.6162
##          Detection Rate : 0.6128
##    Detection Prevalence : 0.6207
##       Balanced Accuracy : 0.9870
##
##        'Positive' Class : 0
##
```

```
df1 <- df %>%
  filter(is.na(Survived))
df1$Survived <- predict(svm1, df1)
```

```
write_csv((df1 %>% select(PassengerId, Survived)), file='My_submission.csv')
```

8 Contribuyentes

Contribuciones	Firma
Investigación previa	
Redacción de las respuestas	
Desarrollo código	

9 References